

PANDUAN TUGAS BESAR

MK: Kecerdasan Buatan

1. Deskripsi dan Tujuan

Tugas besar ini bersifat project-based: mahasiswa memilih masalah nyata, memilih dataset publik yang relevan, lalu membangun dan menganalisis model Deep Neural Network (DNN) secara mandiri.

Yang dinilai BUKAN seberapa tinggi akurasi model, melainkan seberapa dalam mahasiswa memahami dan mampu menjelaskan setiap keputusan teknis yang mereka buat — dari preprocessing hingga aktivasi output. Mendapatkan hasil yang kurang baik namun dapat menjelaskan konsep solusi yang diusulkan dapat mendapatkan skor yang baik.

1.1 Tujuan Pembelajaran

Setelah menyelesaikan tugas ini, mahasiswa mampu:

- Merancang pipeline deep learning end-to-end untuk masalah nyata
- Memilih dan menerapkan preprocessing data yang tepat beserta justifikasinya
- Membangun dan menjelaskan arsitektur DNN (MLP, CNN 1D, CNN 2D, atau variannya)
- Menginterpretasikan setiap komponen layer, fungsi aktivasi, dan fungsi loss
- Melakukan visualisasi fitur dan aktivasi untuk memahami perilaku model
- Menerapkan strategi evaluasi yang benar: train/dev/test split dan cross-validation
- Menjelaskan konsep batch size dan dampaknya terhadap pelatihan
- Mengkomunikasikan temuan secara lisan dalam presentasi yang direkam dan diunggah ke YouTube

2. Arsitektur yang Diperbolehkan

Mahasiswa bebas memilih salah satu atau kombinasi arsitektur berikut, disesuaikan dengan jenis data dan masalah yang dipilih:

Arsitektur	Cocok Untuk	Contoh Kasus
MLP — Multi-Layer Perceptron	Data tabular, fitur numerik	Kebugaran, keuangan, sensor tunggal
CNN 1D	Sinyal, time-series, tabular direshape	ECG, vibrasi, audio, akselerometer
CNN 2D	Data citra / gambar 2D	Klasifikasi gambar, deteksi objek sederhana
CNN 2D + MLP (Hybrid)	Citra + metadata tabular	Diagnosis medis dengan data klinis
Varian lain	Bebas, dengan justifikasi penuh	Harus mampu dijelaskan sepenuhnya

Syarat wajib: Apapun arsitektur yang dipilih, mahasiswa harus mampu menjelaskan setiap layer secara konseptual. Menggunakan arsitektur yang lebih kompleks tanpa pemahaman akan menghasilkan nilai lebih rendah dari arsitektur sederhana yang dipahami secara mendalam.

3. Konsep Wajib yang Harus Dijelaskan

Berikut adalah daftar konsep yang **wajib muncul dan dijelaskan** dalam laporan dan presentasi. Tidak ada urutan baku — integrasikan secara natural ke dalam narasi proyek.

3.1 Preprocessing Data

Jelaskan **setiap langkah preprocessing** yang dilakukan dan **mengapa** langkah tersebut diperlukan untuk dataset spesifik yang dipilih. Jawab pertanyaan-pertanyaan berikut dalam laporan:

- Apakah ada **missing values**? Bagaimana cara menanganinya (drop, imputation) dan mengapa metode itu dipilih?
- Apakah perlu **normalisasi atau standardisasi** fitur? Metode mana yang dipilih (Min-Max, StandardScaler, dll.) dan apa risikonya jika tidak dilakukan?
- Apakah ada **fitur kategorikal**? Bagaimana encoding-nya (one-hot, label encoding)? Apa perbedaannya?
- Untuk CNN 1D: bagaimana cara merestrukturisasi data tabular menjadi bentuk (n_samples, timesteps, channels)?
- Untuk CNN 2D: apakah gambar perlu diubah ukurannya, dinormalisasi ke [0, 1], atau dikonversi grayscale?
- Apakah kelas target **seimbang (balanced)**? Jika tidak, langkah apa yang diambil (oversampling, class weights)?

Catatan kritis — Data Leakage:

Normalisasi/standardisasi harus dilakukan **setelah** split data. Scaler di-fit hanya pada training set, lalu di-transform ke dev dan test set. Melakukan fit scaler pada seluruh dataset sebelum split adalah data leakage yang akan menghasilkan estimasi performa yang terlalu optimistis.

3.2 Penjelasan Setiap Layer dalam Arsitektur

Untuk setiap layer dalam model yang dibangun, jelaskan fungsinya secara matematis dan konseptual:

Dense Layer (Fully Connected)

- **Operasi matematis:** $\text{output} = \text{activation}(W \cdot x + b)$ — jelaskan W , x , dan b .
- Mengapa jumlah neuron dipilih sebesar itu? Apa konsekuensi jika terlalu sedikit atau terlalu banyak?
- Bagaimana memutuskan berapa banyak hidden layer yang digunakan?

Conv1D / Conv2D Layer

- **Kernel/filter:** apa itu dan bagaimana ia bergerak (sliding window) di atas input?
-

- **Parameter penting:** jelaskan arti filters, kernel_size, strides, dan padding.
- Mengapa CNN efektif untuk data sekuensial (1D) atau data citra (2D) dibanding MLP yang sepenuhnya connected?

Pooling Layer (MaxPooling, AveragePooling, GlobalAveragePooling)

- Apa fungsi pooling dalam arsitektur CNN? Apa yang hilang dan apa yang dipertahankan?
- Kapan GlobalAveragePooling lebih baik dari Flatten sebagai transisi ke Dense layer?

Flatten

- Kapan Flatten dibutuhkan dan kapan bisa digantikan oleh GlobalAveragePooling? Jelaskan perbedaan dimensi outputnya.

3.3 Fungsi Aktivasi Output Layer

Aktivasi output harus selaras dengan jenis tugas:

Jenis Tugas	Aktivasi Output	Alasan
Klasifikasi biner	sigmoid	Output berupa probabilitas antara 0 dan 1 untuk satu kelas
Klasifikasi multi-kelas (mutually exclusive)	softmax	Output berupa distribusi probabilitas yang jumlahnya = 1
Klasifikasi multi-label	sigmoid (per neuron)	Setiap kelas independen — masing-masing menghasilkan probabilitas sendiri
Regresi (tak terbatas)	linear (tanpa aktivasi)	Output adalah nilai kontinu tanpa batas atas/bawah
Regresi terbatas (misal: 0–1)	sigmoid	Membatasi output dalam rentang [0, 1]

Pertanyaan wajib dijawab dalam laporan:

Jika saya menggunakan aktivasi yang salah (misalnya sigmoid untuk regresi, atau linear untuk klasifikasi biner), apa yang akan terjadi pada output model dan proses optimasi? Berikan argumen matematis atau tunjukkan secara empiris.

3.4 Fungsi Loss

Jelaskan fungsi loss yang dipilih dan kaitannya dengan aktivasi output layer. Fungsi loss dan aktivasi output adalah pasangan yang tidak boleh dipisahkan.

Binary Cross-Entropy — untuk klasifikasi biner

- Mengapa ini lebih tepat dari MSE untuk klasifikasi? Kaitkan dengan masalah saturasi gradien pada fungsi sigmoid.
- Kapan gunakan `binary_crossentropy` vs `categorical_crossentropy`? Apa bedanya?

Categorical Cross-Entropy — untuk klasifikasi multi-kelas

- Kapan gunakan `sparse_categorical_crossentropy` vs `categorical_crossentropy`? Perbedaan format label mana yang berlaku?

Mean Squared Error — untuk regresi

- Apa kelemahan MSE terhadap outlier? Kapan sebaiknya diganti dengan Huber Loss atau MAE?
- Apa implikasi menggunakan `mean_absolute_error` sebagai loss vs sebagai metrik evaluasi?

Yang wajib didiskusikan: Tunjukkan apa yang terjadi (secara teoritis atau empiris) jika Anda menggunakan fungsi loss yang tidak sesuai dengan jenis tugas — misalnya, menggunakan MSE untuk klasifikasi biner atau binary cross-entropy untuk regresi.

3.5 Pemisahan Data: Train, Dev (Validation), dan Test Set

Jelaskan strategi pemisahan data yang digunakan beserta justifikasi rasionya:

Set	Peran	Digunakan untuk
Training set	Melatih model	Update bobot melalui backpropagation
Dev set (Validation)	Memantau generalisasi	Tuning hyperparameter, early stopping, pemilihan arsitektur
Test set	Evaluasi final jujur	Melaporkan performa sesungguhnya — TIDAK boleh disentuh sebelum model final

Pertanyaan yang harus dijawab dalam laporan:

- Rasio split yang digunakan (misal 70/15/15 atau 80/10/10) dan mengapa rasio tersebut dipilih untuk ukuran dataset ini?
- Apakah digunakan stratified split? Jika ya, mengapa penting untuk dataset yang tidak seimbang?
- **Apakah pemisahan train-dev-test selalu diperlukan?** Diskusikan: jika dataset sangat kecil (< 500 sampel), apakah test set masih relevan? Kapan cukup menggunakan hanya train-val?
- Bagaimana memastikan tidak ada data leakage antara set-set tersebut, terutama saat melakukan preprocessing?

Peringatan kritis: Dev set digunakan berulang kali selama eksperimen, sehingga secara tidak langsung informasinya 'bocor' ke proses pemilihan model. Oleh karena itu, test set yang benar-benar independen tetap diperlukan untuk melaporkan performa yang jujur dan tidak bias.

3.6 Cross-Validation

Jelaskan kapan dan mengapa cross-validation digunakan, khususnya ketika dataset kecil dan single split tidak representatif:

K-Fold Cross-Validation

- Data dibagi menjadi K fold; model dilatih K kali, setiap kali menggunakan fold berbeda sebagai validation set.
- Estimasi performa lebih robust dibanding single train-val split karena seluruh data digunakan sebagai validation.
- **Cocok ketika dataset kecil** (< 1.000 sampel) sehingga satu split saja tidak representatif.

Stratified K-Fold

- Versi K-Fold yang mempertahankan proporsi kelas di setiap fold.
- Wajib digunakan untuk dataset klasifikasi yang tidak seimbang (imbalanced classes).

Yang harus dijawab:

- Apakah dataset Anda cukup besar sehingga single train-dev-test split sudah memadai, ataukah perlu K-Fold?
- Jika menggunakan K-Fold, bagaimana cara menggabungkan hasil dari K model (rata-rata metrik? voting ensemble?)
- Apa trade-off antara K-Fold (akurasi estimasi performa lebih tinggi) vs single split (efisiensi komputasi)?

3.7 Batch Size dalam Training

Jelaskan konsep batch size dan dampaknya terhadap training:

Jenis Batch	Definisi	Karakteristik
Full-batch (batch = N)	Gradient dihitung dari seluruh data sekaligus	Stabil, akurat, tapi lambat dan butuh memori besar

Mini-batch (batch = 32, 64, ...)	Gradient dihitung dari subset data	Noise kecil membantu generalisasi — pilihan paling umum
Stochastic (batch = 1)	Gradient dihitung dari satu sampel	Sangat noise, lambat konvergen, tapi bisa lolos dari local minimum

Yang harus didiskusikan dalam laporan:

- Batch size yang digunakan dalam proyek dan alasan pemilihannya.
- Bagaimana batch size memengaruhi kecepatan training (iterasi per epoch) vs stabilitas konvergensi?
- Apakah ada eksperimen yang membandingkan batch size berbeda? Tampilkan kurva loss-nya.
- **Hubungan batch size dan learning rate:** ketika batch size dinaikkan 2×, apakah learning rate perlu disesuaikan? Jelaskan mengapa (Linear Scaling Rule).

3.8 Visualisasi Fitur dan Aktivasi Model

Bagian ini membedakan laporan yang baik dari laporan yang luar biasa. Mahasiswa harus berusaha **memahami apa yang dipelajari model**, bukan hanya melihat angka akhirnya.

Untuk MLP

- Visualisasikan distribusi bobot setiap layer setelah training — apakah ada neuron mati (semua bobot mendekati nol)?
- Plot distribusi aktivasi dari setiap hidden layer pada sampel test — apakah ReLU menghasilkan banyak nilai nol (dying ReLU problem)?
- Hitung dan visualisasikan feature importance menggunakan permutation importance atau gradient-based saliency.

Untuk CNN 1D

- Visualisasikan output setiap filter konvolusi (feature map) untuk beberapa sampel — pola apa yang ditangkap filter tersebut?
- Plot bobot filter konvolusi dan interpretasikan pola yang mereka deteksi dalam konteks domain data.

Untuk CNN 2D

- Visualisasikan feature map dari Conv layer pertama untuk beberapa gambar input — apa yang dideteksi layer awal (edge, tekstur, warna)?
- Implementasikan Grad-CAM atau saliency map untuk menunjukkan area gambar yang paling memengaruhi keputusan model.

Minimal yang harus ada dalam laporan:

- **Wajib untuk semua:** Kurva training loss vs validation loss per epoch
- **Wajib untuk semua:** Confusion matrix (klasifikasi) atau scatter plot prediksi vs aktual (regresi)
- **Wajib minimal satu:** Visualisasi internal model — feature map, weight distribution, Grad-CAM, atau saliency map

4. Tema dan Ide Proyek

Mahasiswa bebas memilih domain apapun. Berikut adalah inspirasi per bidang (ini bukan batasan):

Domain	Contoh Masalah	Arsitektur Disarankan	Dataset Referensi
Kesehatan & Medis	Deteksi aritmia dari sinyal ECG	CNN 1D	PhysioNet, Kaggle ECG
Kesehatan & Medis	Prediksi risiko diabetes	MLP	UCI Pima Indians
Energi & Listrik	Deteksi gangguan kualitas daya	CNN 1D	SCADA logs, simulasi
Manufaktur	Klasifikasi kerusakan bearing	CNN 1D	CWRU Bearing Dataset
Computer Vision	Klasifikasi gambar sederhana	CNN 2D	CIFAR-10, Kaggle custom
Pertanian & Pangan	Rekomendasi tanaman	MLP	Crop Recommendation (Kaggle)
Olahraga & HAR	Pengenalan aktivitas fisik	CNN 1D	UCI HAR Dataset
Keamanan Jaringan	Deteksi intrusi jaringan	MLP	NSL-KDD Dataset

5. Format Laporan Tertulis

Laporan ditulis dalam **Bahasa Indonesia**, minimal **20 halaman** tidak termasuk kode program. Format file: **PDF**.

Bab 1 — Pendahuluan

- **Latar belakang:** mengapa masalah yang dipilih penting secara teknis maupun sosial?
- **Rumusan masalah:** pertanyaan spesifik yang akan dijawab oleh proyek ini
- **Tujuan:** apa yang ingin dicapai
- **Batasan:** dataset yang digunakan, framework, jenis arsitektur, lingkup eksperimen

Bab 2 — Tinjauan Dataset

- Sumber dataset, cara mendapatkannya, lisensi penggunaan
- Deskripsi fitur-fitur: tabel lengkap nama, tipe data, satuan, rentang nilai
- Statistik deskriptif: mean, std, min, max, distribusi
- Visualisasi distribusi fitur dan target
- Identifikasi tantangan: missing values, imbalance kelas, outlier

Bab 3 — Metodologi

3.1 Alur Kerja (Pipeline)

Gambarkan diagram alur lengkap: *Input Data* → *EDA* (Exploratory Data Analysis) → *Preprocessing* → *Model Design* → *Training* → *Evaluation* → *Conclusion*.

3.2 Preprocessing

Jelaskan setiap langkah preprocessing secara rinci (lihat Bagian 3.1 panduan ini). Sertakan kode Python yang relevan dan output visualnya.

3.3 Strategi Pemisahan Data

Jelaskan rasio train/dev/test dan justifikasinya. Diskusikan apakah cross-validation diperlukan untuk dataset ini (lihat Bagian 3.5 dan 3.6 panduan ini).

3.4 Arsitektur Model

Tuliskan arsitektur secara lengkap dengan justifikasi setiap layer. Sertakan output dari `model.summary()`. Jelaskan mengapa aktivasi output dan fungsi loss dipilih seperti itu.

3.5 Konfigurasi Training

- **Optimizer** yang digunakan (Adam, SGD, dll.) dan learning rate — mengapa pilihan ini?
- **Batch size** — mengapa ukuran ini dipilih? (lihat Bagian 3.7 panduan ini)
- **Jumlah epoch** dan strategi early stopping — pada kondisi apa training dihentikan?
- **Teknik regularisasi** yang digunakan: Dropout rate, BatchNorm, L2 weight decay

Bab 4 — Hasil dan Analisis

4.1 Kurva Training

Tampilkan dan analisis kurva training loss vs validation loss. Identifikasi: apakah model konvergen? Apakah ada tanda overfitting? Pada epoch berapa model mencapai performa optimal?

4.2 Visualisasi Internal Model

Sertakan minimal satu visualisasi internal (feature map, weight distribution, saliency map, Grad-CAM). Interpretasikan apa yang terlihat dalam konteks masalah yang dipilih.

4.3 Evaluasi pada Test Set

Untuk klasifikasi: laporkan Accuracy, Precision, Recall, F1-Score, AUC-ROC. Sertakan confusion matrix.

Untuk regresi: laporkan MSE, MAE, RMSE, R^2 Score. Sertakan scatter plot prediksi vs nilai aktual.

4.4 Tabel Eksperimen

Dokumentasikan **semua eksperimen** yang dilakukan, bukan hanya yang terbaik:

Eksperimen	Arsitektur	LR	Batch	Dropout	Val Loss	Test Score	Catatan
Baseline	MLP 2-layer	0.001	32	0.0			Titik awal

Exp-02	MLP 3-layer	0.001	32	0.3			Tambah kedalaman model
Exp-03	CNN 1D	0.0005	64	0.3			Arsitektur baru
Exp-04	...	...	...	...			...

Bab 5 — Pembahasan

Ini adalah bab terpenting. Jawab pertanyaan-pertanyaan berikut secara mendalam:

- Mengapa arsitektur yang dipilih sesuai untuk masalah ini? Apa kelebihan dan kekurangannya?
- Apa yang ditunjukkan oleh kurva training? Bagaimana cara mengatasi overfitting, underfitting, atau konvergensi lambat?
- Apa yang ditunjukkan visualisasi internal model? Apakah model belajar fitur yang masuk akal secara domain?
- Bagaimana perbandingan antar eksperimen? Apa faktor yang paling berpengaruh terhadap performa?
- Apa keterbatasan pendekatan ini dan bagaimana cara memperbaikinya jika ada waktu lebih?

Bab 6 — Kesimpulan dan Saran

- Ringkasan temuan utama dalam poin-poin yang jelas
- Jawaban terhadap rumusan masalah di Bab 1
- Saran konkret untuk pengembangan lanjutan

Lampiran

- Kode Python lengkap (Notebook Jupyter / Google Colab) — **harus reproducible**
- Output `model.summary()` dari setiap model yang diuji
- Tabel eksperimen lengkap jika tidak masuk di Bab 4

6. Format Presentasi dan Video YouTube

Presentasi direkam, diunggah ke YouTube (unlisted atau public), dan link-nya dikumpulkan bersama laporan.

6.1 Struktur Presentasi (Total: 15–20 Menit)

Segmen	Durasi	Isi
Pembukaan	1–2 menit	Perkenalan, masalah yang dipilih, mengapa masalah ini penting secara teknis dan praktis
Dataset & EDA (Exploratory Data Analysis)	2–3 menit	Deskripsi data, temuan EDA, tantangan yang ditemukan, visualisasi distribusi
Preprocessing	2–3 menit	Langkah-langkah preprocessing, justifikasi setiap keputusan, demonstrasi live di notebook
Arsitektur Model	3–4 menit	Penjelasan setiap layer, pilihan aktivasi output dan loss function, konfigurasi batch size
Training & Evaluasi	3–4 menit	Kurva training, metrik evaluasi, visualisasi internal model, tabel eksperimen
Pembahasan & Insight	2–3 menit	Apa yang dipelajari, keterbatasan model, saran perbaikan
Penutup	1 menit	Kesimpulan singkat, ajakan diskusi atau pertanyaan

6.2 Persyaratan Teknis Video

- **Format rekaman:** Screen recording dengan wajah pembicara terlihat di pojok layar
 - **Resolusi:** Minimal 720p (1280×720)
 - **Judul video YouTube:** [Tugas Besar DL] Nama Ketua Kelompok — Judul Proyek — Tahun
 - **Deskripsi video:** Cantumkan nama anggota, NIM, dan link Google Colab/GitHub
-